

Inteligencia Computacional

TRABAJO FINAL INTEGRADOR SISTEMA DE DETECCIÓN DE ACORDES EN INSTRUMENTOS

Alumnos:

Braian Marcelo López

Facundo Manuel Altamirano

Giovani López

Grupo N°4

Profesores Responsables:

Matías Gabriel Krujoski

Axel Alfredo Skrauba

Sabrina Daiana Pryszczuk

Oberá, Misiones, 29/06/2026

 Facultad de Ingeniería OBERA Universidad Nacional de Misiones	Grupo N°4 – López Braian, Altamirano Facundo, López Giovani
	TRABAJO FINAL INTEGRADOR

Contenidos

Objetivos	4
Introducción	4
Conceptos pertinentes.....	4
Escalas.....	4
Acordes	5
Transformada de Constante Q (CQT).....	6
Simbología.....	7
Análisis Exploratorio de Datos	7
Estructura del dataset y etiquetado.....	8
Análisis Acústico y Representaciones Espectrales	8
Distribución y Balance de Clases.....	9
Modelos y Arquitecturas	11
Transfer learning: <i>Audio Spectrogram Transformer</i> + perceptron multicapa	11
Segmentación por ventana deslizante	11
Etiquetado	12
Entrenamiento	12
Test.....	13
Modelos entrenados desde cero	15
Integración del <i>GuitarSet</i>	15
Preprocesamiento con CQT	15
Segmentación de ventanas temporales.....	16
LSTM.....	17
Conv1D	17
Entrenamiento	18

 Facultad de Ingeniería OBERA Universidad Nacional de Misiones	Grupo N°4 – López Braian, Altamirano Facundo, López Giovani
	TRABAJO FINAL INTEGRADOR

Postprocesamiento	19
Resultados	20
CONCLUSIONES.....	24
Bibliografía	26

 Facultad de Ingeniería OBERA Universidad Nacional de Misiones	Grupo N°4 – López Braian, Altamirano Facundo, López Giovani
	TRABAJO FINAL INTEGRADOR

Objetivos

Este proyecto se constituye como un primer estudio de viabilidad para un modelo capaz de detectar acordes de guitarra en múltiples dominios, involucrando escenarios con otros instrumentos y/o con voces de fondo.

Introducción

El Reconocimiento Automático de Acordes representa uno de los desafíos fundamentales dentro del campo de la Recuperación de Información Musical (MIR). Identificar la progresión armónica de una pieza de audio no solo es esencial para la transcripción musical automática, sino que también sirve como base para tareas más complejas como la recomendación de canciones, la separación de fuentes sonoras y el análisis de la estructura musical.

Cuando un acorde es ejecutado, la señal resultante no solo contiene las frecuencias fundamentales de las notas que lo componen, sino también un denso entramado de armónicos que varían drásticamente dependiendo del timbre del instrumento. Además, factores expresivos humanos, como variaciones en el tempo (BPM) o técnicas específicas de ejecución —por ejemplo, el rasgueo escalonado en una guitarra versus el ataque percusivo simultáneo en un piano— añaden capas de variabilidad que dificultan la clasificación mediante algoritmos de procesamiento de señales tradicionales.

Para abordar esta problemática, el presente trabajo propone el desarrollo y evaluación de un modelo de aprendizaje profundo basado en una Red Neuronal Convolucional (CNN). Las arquitecturas convolucionales han demostrado un éxito excepcional en la clasificación de patrones espaciales, y al transformar el audio unidimensional en representaciones de tiempo-frecuencia (espectrogramas), es posible aprovechar esta capacidad para que la red extraiga características armónicas de forma autónoma, volviéndose invariante a variaciones de tono y tiempo.

Conceptos pertinentes

Escalas

Una escala musical es una secuencia ordenada de frecuencias sonoras (notas) que divide la octava en intervalos específicos. En la música occidental, el sistema predominante es el temperamento igual de 12 notas (12-TET), donde la octava se divide en 12 semitonos espaciados logarítmicamente. A partir de estas 12 notas cromáticas, se construyen escalas diatónicas (como la Mayor y la Menor

natural) seleccionando secuencias específicas de 7 notas, las cuales definen la tonalidad de una obra musical.

En el contexto del Reconocimiento Automático de Acordes (ACE), las escalas son fundamentales, ya que dictan las relaciones armónicas probables y restringen el espacio de búsqueda; los acordes que componen una pieza suelen pertenecer a la escala de su tonalidad subyacente, lo que permite a los modelos predictivos inferir secuencias lógicas de acordes en lugar de transiciones aleatorias.

Escala mayor											
I	II	III	IV	V	VI	VII					
DO	RE	MI	FA	SOL	LA	SI	DO	RE	MI	FA	SOL
C	D	E	F	G	A	B	C	D	E	F	G
							I	II	III	IV	V
							Escala menor natural				

Ilustración 1: Escalas mayor y menor naturales.

Acordes

Un acorde es la combinación de tres o más notas de diferente tono ejecutadas de forma simultánea o en una sucesión temporal inmediata (arpeggio). En la teoría musical occidental y bajo el sistema de 12-TET, las unidades fundamentales son las tríadas (acordes de tres notas), las cuales se construyen superponiendo intervalos de tercera a partir de una frecuencia fundamental o raíz f_0 .

- **Tríada Mayor:** Constituida por la raíz f_0 , su tercera mayor ($f_1 = f_0 \cdot 2^{4/12}$) y su quinta justa ($f_2 = f_0 \cdot 2^{7/12}$).
- **Tríada Menor:** Constituida por la raíz f_0 , su tercera menor ($f_1 = f_0 \cdot 2^{3/12}$) y su quinta justa ($f_2 = f_0 \cdot 2^{7/12}$).

 Facultad de Ingeniería OBERA Universidad Nacional de Misiones	Grupo N°4 – López Braian, Altamirano Facundo, López Giovani
	TRABAJO FINAL INTEGRADOR

En el ámbito de la MIR y el ACE, los acordes actúan como descriptores de alto nivel de la estructura armónica y tonal de una señal de audio. Representan una discretización del espectro sonoro continuo en categorías simbólicas finitas, facilitando que algoritmos de aprendizaje computacional procesen características de frecuencia y tiempo (como las obtenidas por la Transformada de Q Constante) para traducirlas en representaciones lógicas de la progresión musical.

ACORDES MAYORES DE PIANO




Ilustración 2: Acordes mayores de piano para las tónicas principales de la escala diatónica.

Transformada de Constante Q (CQT)

La Transformada de Q Constante (CQT) es una representación de tiempo-frecuencia donde las frecuencias de análisis se distribuyen de manera geométrica (logarítmica), manteniendo constante la relación entre la frecuencia central y el ancho de banda del filtro. Esta relación matemática se define a través del factor de calidad Q :

$$Q = \frac{f_k}{\Delta f_k}$$

donde f_k es la frecuencia central del canal k y Δf_k representa su ancho de banda asociado.

A diferencia de la Transformada Corta de Fourier (STFT), cuya resolución de frecuencias es lineal, la CQT se alinea de forma natural con la percepción psicoacústica humana y la estructura de la escala musical 12-TET, en la cual las frecuencias de las notas se suceden según la relación:

$$f_k = f_0 \cdot 2^{\frac{k}{B}}$$

donde f_0 es la frecuencia mínima de análisis y B es el número de divisiones (o *bins*) por octava.

Adicionalmente, para preservar el valor de Q constante, la longitud de la ventana de análisis N_k varía dinámicamente para cada frecuencia según la ecuación:

 Facultad de Ingeniería OBERA Universidad Nacional de Misiones	Grupo N°4 – López Braian, Altamirano Facundo, López Giovani
	TRABAJO FINAL INTEGRADOR

$$N_k = Q \cdot \frac{f_s}{f_k}$$

siendo f_s la frecuencia de muestreo del sistema. Esto resulta en ventanas más largas (mejor resolución frecuencial) para registrar las notas graves y ventanas más cortas (mejor resolución temporal) para las notas agudas. Esta flexibilidad matemática la convierte en la herramienta de extracción de características por excelencia para tareas de MIR, tales como el ACE.

Simbología

A continuación, se listan los símbolos y códigos utilizados para representar los acordes que identifica el modelo:

Tabla 1: Símbolos utilizados en los modelos, con sus respectivos significados y ejemplos de uso

Símbolo	Significado	Ejemplo
Maj	Tríada mayor	C_Maj (Do Mayor)
Min	Tríada menor	C_Min (Do Menor)
Dim	Tríada disminuida	C_Dim (Do Disminuido)
Aug	Tríada aumentada	C_Aug (Do Aumentado)
#	Primera sostenida	F#_Aug (Fa Sostenido Aumentado)

Análisis Exploratorio de Datos

Un obstáculo común en el entrenamiento de este tipo de modelos supervisados es la disponibilidad de conjuntos de datos (datasets) masivos con un etiquetado preciso, a nivel de milisegundo. Por ello, como parte fundamental de este proyecto, se diseñó un flujo de trabajo para la generación, mediante las librerías PrettyMIDI y FluidSynth, de un dataset sintético altamente controlado, pero acústicamente realista. Este conjunto de datos se centró en progresiones de tríadas mayores, menores, aumentadas, y disminuidas, introduciendo dinámicamente variaciones de tempo y emulando articulaciones instrumentales específicas (como el *strumming* de la guitarra y acordes en bloque de piano), garantizando así que la red neuronal generalice sobre las relaciones interválicas y no memorice artefactos del audio.

En conjunto con los audios sintéticos se utilizaron muestras de *GuitarSet* [1], un dataset de 360 muestras de grabaciones de guitarra en géneros de rock, jazz, funk, bossa nova y *singer – songwriter*,

 Facultad de Ingeniería OBERA Universidad Nacional de Misiones	Grupo N°4 – López Braian, Altamirano Facundo, López Giovani
	TRABAJO FINAL INTEGRADOR

con sus respectivas anotaciones de acordes e intervalos de tiempo. El mismo es un estándar en la industria para las tareas relacionadas con MIR.

Antes de proceder con el entrenamiento de la Red Neuronal Convolucional, es imperativo comprender la estructura, distribución y características acústicas del conjunto de datos generado. El Análisis Exploratorio de Datos (EDA) permite validar que la síntesis de audio cumpla con los requisitos de variabilidad y balance necesarios para una correcta generalización del modelo.

Estructura del dataset y etiquetado

Para optimizar los recursos computacionales y garantizar un aprendizaje equitativo, se extrajo un subconjunto representativo (*subset*) compuesto por 2.000 archivos de audio únicos, distribuidos uniformemente entre 1.000 muestras de guitarra y 1.000 muestras de piano.

Tabla 2: Etiquetas generadas para los audios sintéticos.

ID	filename	instrument	bpm	start_time	end_time	chord	triad_type
0	mixta/prog_mixta_0_Piano.wav	Piano	135	0.000000	0.888889	F_Aug	Aug
1	mixta/prog_mixta_0_Piano.wav	Piano	135	0.888889	1.777778	F#_Min	Min
2	mixta/prog_mixta_0_Piano.wav	Piano	135	1.777778	2.666667	F_Maj	Maj
3	mixta/prog_mixta_0_Piano.wav	Piano	135	2.666667	3.555556	F_Maj	Maj
4	mixta/prog_mixta_0_Guitar.wav	Guitar	98	0.000000	1.224490	F_Dim	Dim

Como se observa en la tabla de etiquetas, cada archivo .wav está subdividido en ventanas temporales (start_time y end_time) que marcan con precisión la duración de cada acorde dentro de la progresión. Resulta crucial destacar la columna bpm, la cual demuestra la variabilidad de tempo inyectada en el dataset (oscilando, por ejemplo, entre 98 y 135 BPM). Esta variación temporal dinámica asegura que el modelo no asocie características de duración absoluta con tipos de acordes específicos, forzando a la red a centrarse exclusivamente en la relación armónica-espectral.

Análisis Acústico y Representaciones Espectrales

Para validar las características acústicas de las muestras generadas, se empleó la librería librosa para la extracción y visualización de espectrogramas de potencia (escala en decibeles) mediante la Transformada Corta de Fourier (STFT).




Ilustración 3: Espectrogramas de ejemplo de audios sintéticos de piano y guitarra.

- **Piano**

- Los armónicos se extienden con mayor intensidad hacia frecuencias altas (hasta aproximadamente 10 kHz).
- Existe una mayor densidad de componentes armónicas.
- Los armónicos permanecen visibles durante buena parte de la duración del acorde.

- **Guitarra**

- La mayor parte de la energía se concentra por debajo de aproximadamente 4–5 kHz.
- Los armónicos superiores pierden intensidad más rápidamente.
- Se observa una estructura armónica ligeramente menos densa.

Esto refleja que el piano posee un espectro más amplio, mientras que la guitarra concentra gran parte de su energía en las frecuencias medias.

Asimismo, la gráfica ilustra claramente cómo los archivos poseen duraciones totales distintas (aproximadamente 6 segundos para la progresión de piano mostrada frente a 7 segundos para la de guitarra), como consecuencia directa de las variaciones aleatorias de BPM introducidas durante la síntesis.

Distribución y Balance de Clases

Se analizó estadísticamente la distribución de los acordes en el *subset* de 2.000 audios (los cuales contienen aproximadamente 8.000 instancias individuales de acordes).




Ilustración 4: Distribución de acordes en el subset.

A nivel macro, el análisis de los tipos de tríadas revela un dataset altamente equilibrado. Las cuatro categorías fundamentales (Menor, Disminuido, Mayor y Aumentado) presentan frecuencias relativas sumamente cercanas, oscilando estrechamente alrededor de las 2.000 instancias por categoría.




Ilustración 5: Distribución por el tipo de tríada

 Facultad de Ingeniería OBERA Universidad Nacional de Misiones	Grupo N°4 – López Braian, Altamirano Facundo, López Giovani
	TRABAJO FINAL INTEGRADOR

Modelos y Arquitecturas

Transfer learning: *Audio Spectrogram Transformer* + perceptron multicapa

Como primer acercamiento, se utilizó como backbone el modelo del MIT *Audio Spectrogram Transformer (AST)* [2]. Este modelo aplica la arquitectura Transformer directamente sobre espectrogramas Mel de audio, sin usar convoluciones. La idea es tratar el espectrograma como si fuera una imagen, recortándolo en parches pequeños que se convierten en embeddings con posición y se pasan por capas de self-attention, la misma base que usa un Vision Transformer, de modo que cada parche puede relacionarse con cualquier otro parche del espectrograma tanto en frecuencia como en tiempo. Fue preentrenado con pesos transferidos de un Vision Transformer entrenado en ImageNet y luego afinado en AudioSet, logrando resultados estado del arte en varios benchmarks de clasificación de audio (0.485 mAP en AudioSet, 95.6% en ESC-50, 98.1% en Speech Commands V2).

A su salida, los embeddings extraídos ingresan a una cabeza de clasificación consistente en capas densas con salida activada por softmax.

Resumen de la cabeza de clasificación:

Layer (type)	Output Shape	Param #
Linear-1	[-1, 512]	393,728
ReLU-2	[-1, 512]	0
Dropout-3	[-1, 512]	0
Linear-4	[-1, 48]	24,624
Softmax-5	[-1, 48]	0

Total params: 418,352
 Trainable params: 418,352
 Non-trainable params: 0

Input size (MB): 0.00
 Forward/backward pass size (MB): 0.01
 Params size (MB): 1.60
 Estimated Total Size (MB): 1.61

Ilustración 6: Cabeza de clasificación de la arquitectura de AST + MLP.

Segmentación por ventana deslizando

Para que el backbone pudiese generar el espacio de embeddings para los audios, se los segmentó en ventanas deslizantes de 0,5 segundos cada una, con un solapamiento de 0,25 seg. Esto permitió focalizar en un acorde por cada ventana de tiempo.

Etiquetado

En pos de verificar que las clases predichas por la cabeza MLP fuesen correctas, se implementó un etiquetado de los segmentos creados con el ventaneo, asociando cada ventana con su etiqueta correspondiente según el intervalo al que pertenecía. En caso de que un segmento se encontrara en la transición entre dos acordes, se le asignó el acorde con el que estuviera etiquetado a la mitad del segmento.

Entrenamiento

El entrenamiento de la cabeza clasificadora se realizó durante 50 épocas, utilizando un *callback* de reducción de *learning rate*

Tabla 3: Resumen del entrenamiento de la cabeza clasificadora MLP

Mejor época de entrenamiento	48
Accuracy entrenamiento	66,93%
Accuracy validación	68,24%
Métrica de pérdida	nn.CrossEntropyLoss()
Pérdida de entrenamiento	3,237
Pérdida de validación	3,229




Ilustración 7: Curvas de pérdida y accuracy para entrenamiento y validación de la cabeza MLP.

Aunque el modelo se entrena por muchas épocas, no consiguió que la pérdida se encuentre por debajo de 3 puntos, ni logró romper el techo del 70% de accuracy.

Test




Ilustración 8: Matriz de confusión para el modelo de AST+MLP en el set de test.

El rendimiento del modelo es dispar entre clases, prediciendo de forma casi perfecta algunos tipos de acordes, pero con otros que no fueron predichos ni una sola vez.

Para entender mejor cómo se producían estos errores, se graficaron en un espectrograma las ventanas de las predicciones para dos audios de ejemplo.

 Facultad de Ingeniería OBERA Universidad Nacional de Misiones	Grupo N°4 – López Braian, Altamirano Facundo, López Giovani
	TRABAJO FINAL INTEGRADOR

En función de lo observado en el test, se determinó no avanzar con el modelo de transfer learning y probar con una arquitectura entrenada desde cero.

Modelos entrenados desde cero

Integración del *GuitarSet*

Se agregaron las 180 muestras de tipo “comp” (*comping* o acompañamiento), es decir, aquellas principalmente compuestas por acordes, a los conjuntos de entrenamiento, validación y test previamente definidos en el subset, dejando todas las muestras de jazz en el set de test, y repartiendo las restantes de forma estratificada en entrenamiento y validación. La decisión de dejar las muestras de jazz para las pruebas se justifica en la necesidad de someter a los modelos a un *domain shift* con respecto a las muestras con las que fue entrenado.

Preprocesamiento con CQT

El preprocesamiento de audio para estos modelos se basa en la Transformada Q Constante (CQT), elegida por su resolución logarítmica en frecuencia, que asigna a cada bin un semitono musical y resulta más adecuada que una STFT convencional para representar relaciones armónicas como las que definen un acorde. Cada clip se carga a una frecuencia de muestreo de 22050 Hz y se calcula su CQT con un `hop_length` de 512 muestras (resolución temporal de aproximadamente 23 ms por frame) y 84 bins de frecuencia, equivalentes a 7 octavas. Se conserva únicamente la magnitud de la transformada, descartando la fase, y esta se guarda en escala lineal sin normalizar globalmente.

Se partió de la hipótesis de que esto representaría una ventaja con respecto al modelo anterior, dado que el backbone infería sobre espectrogramas Mel, con una concepción lineal de la frecuencia que no favorece a la identificación de las notas.

A continuación, se presenta un ejemplo de espectrograma generado con la STFT (Ilustración 11) en contraste con uno generado con la CQT (Ilustración 12).




Ilustración 11: Espectrograma generado para un audio de jazz del GuitarSet con STFT.




Ilustración 12: Espectrograma generado para un audio de jazz del GuitarSet con CQT

Segmentación de ventanas temporales

Para muestrear los audios de entrenamiento se consideró la duración mínima de un acorde, la cual depende del estilo, tempo y métrica de la pieza. Como referencia teórica inicial se tomó un compás 4/4 a 90 BPM, equivalente a aproximadamente 2,6 segundos, valor que se usó únicamente como cota

superior de partida. A falta de un método analítico para determinar el tamaño óptimo de ventana, se realizaron pruebas empíricas con distintos valores de duración y paso, evaluando el desempeño resultante en cada caso. A cada ventana se le asigna como etiqueta el acorde correspondiente a su instante temporal central, obteniendo finalmente tensores de forma (N, 21, 84) listos para alimentar los modelos de clasificación.

LSTM

La elección de la LSTM como alternativa se sustenta en su propiedad recurrente, misma que le permite mantener una ventana de contexto sobre cada ventana. Esto se consideró, en una primera instancia, una ventaja para el aprendizaje de los efectos que experimenta el sonido real, tales como el desvanecimiento o las reverberaciones.

Layer (type)	Output Shape	Param #
cqt_input (InputLayer)	(None, 21, 84)	0
lstm1 (LSTM)	(None, 21, 128)	109,056
drop1 (Dropout)	(None, 21, 128)	0
lstm2 (LSTM)	(None, 64)	49,408
drop2 (Dropout)	(None, 64)	0
dense1 (Dense)	(None, 128)	8,320
drop3 (Dropout)	(None, 128)	0
output (Dense)	(None, 48)	6,192

Total params: 172,976 (675.69 KB)
Trainable params: 172,976 (675.69 KB)
Non-trainable params: 0 (0.00 B)

Ilustración 13: Arquitectura LSTM

Conv1D

Se utilizó Conv1D debido a su capacidad para detectar patrones y, como solo se requiere avanzar una dimensión en el análisis de acordes de una canción, se tomó como primer modelo al ser simple, rápido y fácil de implementar.

 Facultad de Ingeniería OBERA Universidad Nacional de Misiones	Grupo N°4 – López Braian, Altamirano Facundo, López Giovani
	TRABAJO FINAL INTEGRADOR

Layer (type)	Output Shape	Param #
cqt_input (InputLayer)	(None, 21, 84)	0
conv1 (Conv1D)	(None, 21, 32)	8,096
bn1 (BatchNormalization)	(None, 21, 32)	128
relu1 (ReLU)	(None, 21, 32)	0
pool1 (MaxPooling1D)	(None, 10, 32)	0
drop1 (Dropout)	(None, 10, 32)	0
conv2 (Conv1D)	(None, 10, 64)	6,208
bn2 (BatchNormalization)	(None, 10, 64)	256
relu2 (ReLU)	(None, 10, 64)	0
pool2 (MaxPooling1D)	(None, 5, 64)	0
drop2 (Dropout)	(None, 5, 64)	0
conv3 (Conv1D)	(None, 5, 128)	24,704
bn3 (BatchNormalization)	(None, 5, 128)	512
relu3 (ReLU)	(None, 5, 128)	0
gap (GlobalAveragePooling1D)	(None, 128)	0
dense1 (Dense)	(None, 128)	16,512
drop3 (Dropout)	(None, 128)	0
output (Dense)	(None, 48)	6,192

Total params: 62,608 (244.56 KB)
Trainable params: 62,160 (242.81 KB)
Non-trainable params: 448 (1.75 KB)

Ilustración 14: Arquitectura Conv1D

Entrenamiento

Para ambos modelos, el proceso de entrenamiento se definió con 50 épocas, un tamaño de lote de 64 y el uso de *callbacks* como *EarlyStopping* y *ReduceLROnPlateau*. La tabla a continuación resume las métricas obtenidas en la mejor época, según lo devuelto por estos mecanismos de control.

Se utilizó *EarlyStopping* con una paciencia de 8 épocas y *ReduceLROnPlateau* de 4 épocas de paciencia.

Tabla 4: Resumen del entrenamiento de LSTM y Conv1D

	LSTM	Conv1D
Mejor época de entrenamiento	1	39
Accuracy entrenamiento	0,3998	0,9046
Accuracy validación	0,6821	0,8773
Métrica de pérdida	sparse_categorical_crossentropy	sparse_categorical_crossentropy
Pérdida de entrenamiento	1,8929	0,2440
Pérdida de validación	1,1151	0,4668

La Ilustración 15 muestra la evolución de las métricas para LSTM y Conv1D. En el modelo Conv1D se observa un comportamiento asintótico a partir de la época 20, lo que hace innecesario prolongar el entrenamiento hasta la 39. Para LSTM, aunque el *EarlyStopping* se activó en la primera época, el análisis visual revela que en la época 5 se minimiza la brecha de pérdida entre entrenamiento y validación, estabilizándose el *accuracy* sin mejoras posteriores aparentes.




Ilustración 15: Comparación de Conv1D vs LSTM

Postprocesamiento

Para seleccionar el tamaño óptimo de la ventana de moda se realizó una búsqueda empírica evaluando el desempeño de ambos modelos (Conv1D y LSTM) sobre el conjunto de test bajo distintos tamaños de ventana, expresados tanto en frames como en su equivalente temporal según el stride utilizado (0,15s). Se comparó la condición sin posprocesado contra ventanas de 2, 4, 7 y 12 frames, equivalentes aproximadamente a 0,5s, 1,0s, 1,86s y 3,0s respectivamente, midiendo en cada caso *accuracy* y WCSR (Weighted Chord Symbol Recall, una métrica que pondera el recall de cada clase de acorde según su frecuencia real, dando más peso a los acordes con mayor presencia temporal en el conjunto evaluado) sobre las predicciones suavizadas frente a las etiquetas reales. La ventana de 7 frames, resultó la que maximizó el WCSR para ambos modelos, superando tanto al baseline sin suavizado como a ventanas más cortas (que no llegaban a corregir errores puntuales de clasificación) y a ventanas más largas (que comenzaban a degradar el desempeño al promediar sobre intervalos que podían abarcar más de un acorde real).




Ilustración 16: Calibración del postprocesado

Resultados

Se evaluó ambos modelos sobre el set de prueba, en la siguiente tabla se resume su desempeño individual.

Tabla 5: Desempeño de los modelos sobre el test set

Modelo	Accuracy Test	Cantidad de parámetros	de Latencia de inferencia (ms)
Conv1D	81,30 %	62.608	91,99
LSTM	63,13 %	172.976	91,73




Ilustración 17: Matriz de confusión LSTM




Ilustración 18: Matriz de confusión Conv1D

La ventaja respecto al modelo basado en embeddings del MIT (AST) es que tanto LSTM como Conv1D no dejan casi ninguna clase sin predicción y presentan una cantidad de errores considerablemente menor en comparación. A esto se suma un tiempo de entrenamiento e inferencia más reducido, junto con una menor cantidad de parámetros del modelo.

Modelo en producción

Se decidió probar el modelo con los 10 primeros segundos de la canción *Yesterday* de *The Beatles* (Ilustración 19), a modo de verificar cómo funcionaba con un audio de un dominio diferente y, de base, más complejo que el que vio en entrenamiento. Para conciliar el vocabulario de acordes extendidos presente en las anotaciones de dicha canción [3] y en las de GuitarSet con las 49 clases del modelo (48 tríadas más silencio), se definió un mapeo de simplificación de calidades. Acordes con séptima, ya sea mayor, menor o dominante, se reducen a su tríada subyacente correspondiente (mayor o menor, según el caso), mientras que las variantes de acordes disminuidos con séptima (semidisminuido y disminuido con séptima) se simplifican a la tríada disminuida. Esta reducción permite aprovechar anotaciones reales que incluyen extensiones armónicas sin necesidad de expandir el espacio de clases del modelo, a costa de perder la información de la séptima específica, ya que el sistema actual no fue entrenado para distinguir ese nivel de detalle.




Ilustración 19: Predicción de acordes de *Yesterday* – *The Beatles*. (Eje Horizontal en segundos)

 Facultad de Ingeniería OBERA Universidad Nacional de Misiones	Grupo N°4 – López Braian, Altamirano Facundo, López Giovani
	TRABAJO FINAL INTEGRADOR

CONCLUSIONES

El presente trabajo abordó el problema del Reconocimiento Automático de Acordes mediante dos enfoques complementarios. En primer lugar, se exploró un esquema de transfer learning utilizando el Audio Spectrogram Transformer del MIT como backbone preentrenado, acoplado a una cabeza de clasificación MLP. Si bien esta arquitectura representa el estado del arte en clasificación general de audio, su desempeño en la tarea específica de ACE resultó limitado, sin superar el 70% de accuracy y con un comportamiento marcadamente dispar entre clases, dejando incluso varias categorías sin predecir ni una sola vez. Esto sugiere que los embeddings preentrenados en AudioSet, orientados a la detección de eventos sonoros generales, no capturan con suficiente especificidad las relaciones armónicas finas que distinguen a un acorde de otro, y que el congelamiento del backbone limitó la capacidad de adaptación del modelo a este dominio particular.

Como segundo enfoque, se entrenaron desde cero dos arquitecturas sobre representaciones CQT, Conv1D y LSTM, combinando el dataset sintético generado con PrettyMIDI y FluidSynth con muestras reales de GuitarSet, lo que permitió exponer a los modelos a un dominio acústico genuino y evaluarlos bajo un corrimiento de dominio controlado mediante la reserva de las muestras de jazz para el conjunto de prueba. Los resultados mostraron una clara superioridad de Conv1D sobre LSTM en todas las métricas relevantes, accuracy de test (81,30% contra 63,13%), consistencia en la matriz de confusión y desempeño sobre canciones reales nunca vistas, pese a contar con casi un tercio de los parámetros del modelo recurrente.

Este resultado contrasta con la hipótesis de partida, que suponía que la capacidad de la LSTM para mantener contexto temporal entre ventanas constituiría una ventaja para modelar fenómenos del sonido real como el desvanecimiento o la reverberación. En la práctica, dicha hipótesis no se vio confirmada, la LSTM mostró señales de subajuste, deteniendo su entrenamiento en la primera época bajo el criterio de EarlyStopping y sin lograr reducir su pérdida de manera comparable a Conv1D. Una explicación plausible es que, dado el tamaño acotado de la ventana temporal utilizada (21 frames, equivalentes a 0,5 segundos), la información relevante para distinguir un acorde está mayoritariamente contenida en la relación instantánea entre bins de frecuencia más que en la dependencia secuencial entre frames consecutivos, favoreciendo así a una arquitectura como Conv1D, orientada a explotar patrones locales en frecuencia, por sobre una diseñada para capturar dependencias de largo alcance en el tiempo.

Finalmente, la incorporación de un esquema de postprocesado por moda deslizante, calibrado empíricamente en una ventana de 7 frames, permitió mejorar la consistencia temporal de las

 Universidad Nacional de Misiones	Grupo N°4 – López Braian, Altamirano Facundo, López Giovani
	TRABAJO FINAL INTEGRADOR

predicciones de ambos modelos. Las pruebas sobre canciones completas y ajenas al dominio de entrenamiento, tanto comerciales como del propio GuitarSet, arrojaron resultados alentadores para Conv1D, en contraste con un desempeño notablemente más débil de LSTM en estas condiciones reales, reforzando la conclusión de que la arquitectura convolucional resultó la más adecuada para este problema dentro del alcance del presente trabajo. Como líneas de trabajo futuro, queda abierta la posibilidad de extender el vocabulario de clases para incluir extensiones armónicas (séptimas, suspensiones), incrementar la proporción de audio real en el entrenamiento para mitigar el corrimiento de dominio observado, y explorar variantes híbridas o un fine-tuning más profundo del AST que permita aprovechar su capacidad de representación sin las limitaciones observadas en este primer acercamiento.

 Facultad de Ingeniería OBRA Universidad Nacional de Misiones	Grupo N°4 – López Braian, Altamirano Facundo, López Giovani
	TRABAJO FINAL INTEGRADOR

Bibliografía

- [1] R. B. J. P. X. Y. a. J. P. B. Q. Xi, «Guitarset: A Dataset for Guitar Transcription,» de *19th International Society for Music Information Retrieval Conference*, Paris, 2018.
- [2] Y.-A. C. J. G. Yuan Gong, *Audio Spectrogram Transformer*, Cornell University, 2021.
- [3] C. Harte, *Towards Automatic Extraction of Harmony Information from Music Signals*, Universidad de Londres, 2010.